

# Pemanfaatan CNN dalam Klasifikasi Motif Batik Indonesia

Arleen Chrysanthia Gunardi (NIM. 13521059)

Program Studi Teknik Informatika  
Sekolah Teknik Elektro dan Informatika  
Institut Teknologi Bandung, Jalan Ganesha 10 Bandung  
E-mail (gmail): chrysantharleen@gmail.com

**Abstrak**—Batik adalah warisan budaya Indonesia yang kaya akan nilai filosofis dan keberagaman motif. Namun, generasi muda kini kurang mengenali keanekaragaman motif batik, yang berisiko mengancam pelestarian seni tradisional batik. Penelitian ini bertujuan untuk mengembangkan model klasifikasi motif batik menggunakan *Convolutional Neural Network* (CNN) guna mendukung upaya pelestarian dan meningkatkan apresiasi terhadap batik. *Dataset* yang digunakan mencakup berbagai jenis motif batik dari beberapa sumber publik, dengan proses augmentasi data untuk meningkatkan performa model. Hasil penelitian menunjukkan bahwa model CNN berbasis arsitektur VGG-16 mampu mencapai akurasi tinggi dalam klasifikasi motif batik. Dengan akurasi validasi rata-rata mencapai 95%, model ini diharapkan dapat digunakan sebagai media edukasi yang efektif untuk generasi muda.

**Kata kunci**—batik; motif; klasifikasi; CNN; VGG-16; pembelajaran mendalam

## I. PENDAHULUAN

Batik merupakan salah satu seni tekstil tradisional Indonesia yang telah diakui sebagai Warisan Kemanusiaan untuk Budaya Lisan dan Nonbendawi oleh UNESCO pada 2 Oktober 2009. Sebagai ikon budaya Nusantara, batik bukan hanya sebagai simbol identitas bangsa, tetapi juga sebagai media serta pewaris tradisi dari generasi ke generasi [1]. Batik mencerminkan keberagaman budaya Indonesia melalui motif dan warna yang khas untuk setiap daerah asalnya. Warna dan motif yang digunakan pada batik umumnya memiliki makna filosofis yang mendalam, menggambarkan nilai-nilai kehidupan, kepercayaan, dan tradisi lokal. Motif batik beragam, beberapa di antaranya adalah motif Batik Parang, Batik Kawung, Batik Mega Mendung, Batik Ceplok, Batik Kraton, dan lain-lain. Menurut sejarahnya, busana batik dapat menentukan kedudukan sosial seseorang.

Seiring perubahan zaman, batik kini kurang diminati oleh generasi muda. Penelitian menunjukkan rata-rata kurang dari 50% responden survei tidak mengenali jenis dan nama motif batik klasik [2]. Terdapat penelitian lain juga yang menyebutkan bahwa generasi muda tidak dapat membedakan motif batik tradisional dan modern, maupun nama atau arti motif batik [3]. Faktor yang menyebabkan fenomena ini adalah kurangnya edukasi mengenai ragam motif batik. Oleh karena

itu, peneliti mulai mengembangkan teknologi untuk melakukan klasifikasi motif batik.

Klasifikasi motif batik dapat dilakukan dengan pengenalan pola berulang pada seni batik. Klasifikasi ini dapat dilakukan dengan pembelajaran mendalam (*deep learning*) yang berperan mengekstraksi fitur pada citra batik dan melakukan pembelajaran untuk mengenali motif batik. Salah satu model pembelajaran mendalam yang dapat digunakan untuk pengenalan pola motif batik untuk klasifikasi adalah *Convolutional Neural Network* (CNN).

Penelitian ini memanfaatkan model arsitektur CNN untuk melakukan klasifikasi jenis-jenis motif batik Indonesia secara akurat. CNN dipilih karena mampu melakukan ekstraksi fitur-fitur pada citra motif batik. Implementasi teknologi ini tidak hanya akan mempermudah proses klasifikasi motif batik, tetapi juga diharapkan dapat meningkatkan kesadaran dan apresiasi generasi muda terhadap kekayaan budaya batik. Dengan demikian, penelitian ini berkontribusi pada pelestarian warisan budaya serta mempromosikan pemanfaatan teknologi modern untuk mendukung keberlanjutan seni tradisional Indonesia.

## II. DASAR TEORI

### A. Klasifikasi Motif Batik

Batik merupakan salah satu ragam seni Indonesia yang merupakan memadukan seni dan teknik nenek moyang. Aneka corak atau motif batik penuh makna serta filosofi. Kini motif batik terus dieksplorasi melalui beragam adat dan budaya yang berkembang di Indonesia. Motif batik adalah corak atau desain berupa perpaduan garis, bentuk, dan isen yang membentuk kerangka gambar batik menjadi kesatuan yang mewujudkan keseluruhan batik [9]. Motif batik meliputi binatang, manusia, dan desain geometris. Dalam konteks sejarah, motif batik sering digunakan untuk menunjukkan status seseorang, misalnya motif Batik Parang yang hanya boleh dikenakan oleh raja, keluarga, serta kerabatnya. Selain itu, pembuatan batik merupakan tradisi yang telah diwariskan secara turun-temurun. Oleh karena itu, motif batik menjadi ciri khas batik yang dihasilkan oleh keluarga tertentu.

Terdapat beberapa motif di Indonesia yang terkait dengan budaya lokal. Salah satu faktor yang mempengaruhi terciptanya motif batik adalah letak geografis. Misalnya, daerah pesisir

menghasilkan batik dengan motif yang berhubungan dengan laut, sementara orang yang tinggal di daerah pegunungan mengambil inspirasi dari alam sekitar. Motif batik juga dipengaruhi oleh sifat, kehidupan, kepercayaan, dan adat istiadat suatu daerah, serta kondisi alam lingkungan [9]. Beberapa motif batik yang umum dikenali di masyarakat di antaranya:

1. Kawung, yaitu motif batik yang berasal dari Yogyakarta dengan bentuk seperti irisan buah kawung (buah kolang-kaling atau buah aren) dan pola bentuk-bentuk geometris yang tersusun secara simetris. Motif batik ini melambangkan keperkasaan dan keadilan, sehingga eksklusif dipakai oleh para pejabat kerajaan [10].
2. Ceplok, yaitu motif batik yang berasal dari Yogyakarta dengan model hiasan berupa satuan demi satuan dengan pola geometris yang berulang. Motif ini terinspirasi dari hiasan dinding candi yang bercorak Hindu dan Buddha, sehingga memberikan makna yang sakral dan mendalam. Pemakaian motif batik ini juga cukup terbatas, yaitu hanya untuk orang-orang tertentu, seperti pegawai kerajaan [11].
3. Parang, yaitu motif batik yang berasal dari Yogyakarta dengan pola diagonal yang berbentuk seperti pedang. Motif ini melambangkan kekuatan serta keberanian. Sama halnya dengan motif batik sebelumnya, batik parang juga eksklusif untuk bangsawan dan keluarga kerajaan sebagai simbol status dan kekuasaan [12].
4. Lereng, yaitu motif batik yang berasal dari daerah Jawa Tengah berupa diagonal yang menyerupai lereng gunung. Motif ini umumnya dipadukan dengan motif lain seperti flora dan fauna, yang melambangkan kekayaan alam dan keberagaman hayati [13].
5. Mega mendung, yaitu motif batik yang berasal dari Cirebon dengan pola menyerupai sekumpulan awan di langit, dipadukan dengan warna gradasi. Secara simbolis, motif ini melambangkan awan gelap yang terlihat saat cuaca yang sejuk. Sejarahnya, motif ini terinspirasi dari motif kebudayaan Tiongkok [14].
6. Nitik, yaitu motif batik yang berasal dari Yogyakarta, melambangkan keanekaragaman melalui coraknya, seperti daun, sulur, dan bunga, serta digambarkan membentuk pola geometris. Pola ini membentuk titik-titik yang memenuhi permukaan kain batik. Elemen hias yang umum pada motif ini adalah ceplokan yang tersusun secara geometris [15].
7. Truntum, yaitu motif batik yang berasal dari Solo dan Yogyakarta, yang biasa dipakai oleh orang tua pengantin pada acara pernikahan. Motif batik ini merupakan simbol cinta yang tulus tanpa syarat, abadi, dan semakin lama terasa semakin subur berkembang (tumaruntum). Coraknya terdiri dari motif bintang di langit berwarna coklat, berlatar hitam dengan kombinasi lambang Garuda [16].

## B. Pembelajaran Mendalam

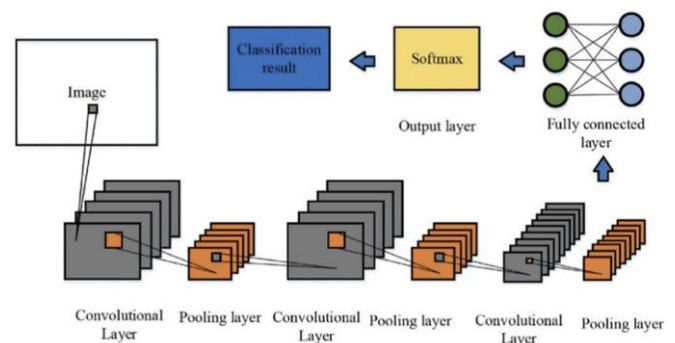
Pembelajaran mendalam (*deep learning*) merupakan bagian dari pembelajaran mesin (*machine learning*) yang berfokus pada pemanfaatan jaringan neural untuk melakukan pekerjaan klasifikasi, regresi, dan pembelajaran representasi. Konsep pembelajaran mendalam terinspirasi dari bidang neurosains yang menumpuk neuron buatan menjadi suatu lapisan dan melatihnya untuk memproses data. Lapisan tersebut mendalam, dengan kata lain terdapat ratusan hingga ribuan lapisan dalam jaringan tersebut [17].

Terdapat beberapa arsitektur jaringan yang umum digunakan untuk pembelajaran mendalam, di antaranya adalah *Convolutional Neural Network*, *Fully Connected Network*, *Recurrent Neural Network*, dan lain-lain. Pemilihan arsitektur jaringan yang tepat berkaitan dengan pekerjaan yang dilakukan, misalnya untuk bidang visi komputer, pembangkitan citra, pengenalan ucapan, atau pemrosesan bahasa alami.

## C. Convolutional Neural Network (CNN)

*Convolutional Neural Network* (CNN) merupakan salah satu arsitektur jaringan neural mendalam yang populer, terutama untuk tugas-tugas yang berhubungan dengan data citra seperti klasifikasi, visi komputer, dan pemrosesan bahasa natural. Berbeda dengan jaringan neural tradisional, CNN menggunakan metode konvolusi untuk berfokus pada area lokal dari suatu citra sehingga mengurangi koneksi yang dibutuhkan secara signifikan dan memungkinkan untuk menganalisis data dengan resolusi yang lebih tinggi [18]. Arsitektur ini merupakan perluasan dari *Artificial Neural Network* (ANN) yang dapat mengekstraksi fitur dari *dataset* yang berbentuk *grid* atau matriks.

Arsitektur CNN terdiri dari beberapa jenis lapisan utama, yaitu lapisan konvolusi, ReLU (*Rectified Linear Unit*), *pooling*, *fully connected*, dan *softmax* (lihat Gambar II.1). Lapisan konvolusi merupakan inti dari CNN yang menggunakan penapis 16 berukuran kecil untuk mendeteksi fitur lokal, seperti tepi, tekstur, atau pola yang lebih kompleks. Setiap penapis menghasilkan peta fitur yang merepresentasikan deteksi fitur pada berbagai posisi dalam citra [19].



Gambar II.1 Arsitektur CNN [19]

Setelah lapisan konvolusi, CNN menerapkan fungsi aktivasi ReLU untuk memperkenalkan sifat non-linier yang memungkinkan jaringan untuk menangani data yang kompleks dan non-linear. ReLU mengubah semua nilai negatif menjadi nol, sehingga mempercepat proses konvergensi jaringan.

Berikutnya adalah lapisan *pooling* yang digunakan untuk mengurangi dimensi spasial dari peta fitur. Lapisan ini membantu mengurangi jumlah parameter dan komputasi dalam jaringan, sehingga jaringan lebih robust terhadap perubahan posisi atau distorsi fitur. Lapisan berikutnya adalah lapisan *fully connected* yang menghubungkan semua neuron dari lapisan sebelumnya ke neuron di lapisan berikutnya, menggabungkan semua fitur yang telah diekstraksi untuk membuat prediksi akhir. Lapisan ini mengambil semua fitur yang telah diproses dan mengolahnya dalam bentuk yang dapat menghasilkan klasifikasi atau keluaran yang diinginkan. Lapisan terakhir adalah lapisan *softmax* untuk tugas klasifikasi dengan mengonversi *output* menjadi probabilitas, sehingga memudahkan interpretasi prediksi model. Setiap *output* dari *softmax* mewakili probabilitas *input* termasuk dalam suatu kelas, sehingga CNN membuat prediksi akhir berdasarkan probabilitas tertinggi [18].

### III. PENELITIAN TERKAIT

Penelitian tentang klasifikasi motif batik telah mengalami perkembangan signifikan seiring dengan kemajuan teknologi. Salah satu studi oleh Ryfial Azhara et al. memanfaatkan metode *Scale-Invariant Feature Transform* (SIFT) untuk ekstraksi fitur dan *Support Vector Machine* (SVM) sebagai *classifier*. Penelitian ini menunjukkan bahwa kombinasi SIFT dan SVM menghasilkan akurasi tinggi hingga 97.67% pada gambar normal, namun akurasi menurun pada gambar yang dirotasi dan diskalakan, masing-masing menjadi 95.47% dan 79%. Metode ini juga menyoroti pentingnya memilih jumlah kluster yang optimal untuk meningkatkan akurasi klasifikasi dan efisiensi waktu komputasi [4].


Studi lain yang membahas klasifikasi batik menggunakan pembelajaran mendalam adalah penelitian oleh Yohanes Gultom et al. yang menggunakan model VGG-16 sebagai ekstraktor fitur melalui *transfer learning* untuk mengklasifikasikan motif batik ke dalam lima kelas utama [5]. Dengan *dataset* yang terdiri dari 2,092 potongan citra batik, model ini mencapai akurasi rata-rata 89% pada *dataset* yang tidak mengalami transformasi. Ini menunjukkan kinerja yang lebih baik jika dibandingkan dengan metode berbasis SIFT dan SURF. Namun, meskipun VGG-16 menunjukkan hasil yang lebih baik pada data yang tidak dirotasi atau diskalakan, model berbasis SIFT masih lebih unggul dalam menangani transformasi seperti rotasi dan skala.

Penelitian lainnya adalah studi yang mengeksplorasi penggunaan CNN, khususnya model VGG-16 dan VGG-19, untuk klasifikasi otomatis motif batik. Studi ini menggarisbawahi tantangan dalam mengenali pola batik yang bervariasi setiap tahun dan pentingnya memahami sejarah di balik setiap pola batik. Hasil penelitian menunjukkan bahwa meskipun model CNN mampu mencapai akurasi hampir 90% dalam kondisi ideal, kinerja menurun signifikan ketika pola batik dirotasi atau diskalakan. Penelitian ini juga menunjukkan bahwa augmentasi data dapat meningkatkan akurasi hingga 10% untuk gambar yang dirotasi atau diskalakan, menunjukkan pentingnya strategi augmentasi dalam meningkatkan robusta model terhadap variasi gambar.

## IV. IMPLEMENTASI

### A. Dataset

*Dataset* batik yang digunakan pada penelitian ini merupakan gabungan dari beberapa sumber *dataset* publik [6], [7], dan [8]. *Dataset* terdiri dari total 2.555 citra untuk pelatihan dan 615 citra untuk validasi. Citra batik pada *dataset* merupakan citra pola batik berwarna, tanpa melibatkan citra batik pada objek tertentu, misalnya citra baju batik. Terdapat tujuh kelas pada *dataset*, yaitu Ceplok (172 citra), Kawung (700 citra), Lereng (61 citra), Megamendung (710 citra), Nitik (117 citra), Parang (700 citra), dan Truntum (710 citra). *Dataset* untuk kelas Ceplok diambil dari gabungan *dataset* kelas Ceplok pada [6] dan [7], sementara kelas Lereng dan Nitik berasal dari *dataset* [6]. *Dataset* kelas Kawung, Megamendung, Parang, dan Truntum berasal dari *dataset* [8]. Adapun sampel *dataset* untuk setiap kelas terdapat pada Gambar IV.1.



Gambar IV.1 Klasifikasi batik, (a) Ceplok, (b) Kawung, (c) Lereng, (d) Megamendung, (e) Nitik, (f) Parang, (g) Truntum

### B. Pra-pemrosesan dan Augmentasi Data

Tahap pra-pemrosesan dan augmentasi data dilakukan untuk mempersiapkan *dataset* sebagai upaya meningkatkan kinerja dan akurasi model. Citra pada *dataset* dinormalisasi dari yang nilai elemennya memiliki skala [0, 255] menjadi [0, 1]. Selain itu, ukuran citra juga ditetapkan menjadi 256 x 256 piksel. Normalisasi dan pengubahan ukuran dilakukan untuk menetapkan standar citra masukan.

Untuk meningkatkan kinerja model, augmentasi data dilakukan. Pada dasarnya, augmentasi data bertujuan untuk mensimulasikan variasi dan distorsi citra masukan yang mungkin dijumpai pada aplikasi sehari-hari. Augmentasi yang dilakukan adalah dengan mengatur sudut rotasi 20 derajat, *shift* secara vertikal dan horizontal 20%, *shear* sebesar 0,2, dan *zoom* sebesar 0,2. Alhasil, *dataset* untuk pelatihan model menjadi lebih beragam, mencegah *overfitting*, serta meningkatkan kinerja model. Model menjadi lebih resilien terhadap transformasi citra.

```

BATCH_SIZE = 32
IMAGE_SIZE = (256, 256)

# Augmentation
train_datagen = ImageDataGenerator(
    rescale=1.0/255,
    rotation_range=20,
    width_shift_range=0.2,
    height_shift_range=0.2,
    shear_range=0.2,
    zoom_range=0.2,
    horizontal_flip=True,
    fill_mode='nearest'
)

test_datagen = ImageDataGenerator(rescale=1.0/255)

train_generator = train_datagen.flow_from_directory(
    train_data_dir,
    batch_size = BATCH_SIZE,
    target_size = IMAGE_SIZE,
    class_mode = "categorical",
    shuffle = True
)

test_generator = train_datagen.flow_from_directory(
    test_data_dir,
    batch_size = BATCH_SIZE,
    target_size = IMAGE_SIZE,
    class_mode = "categorical",
    shuffle = False
)

```

telah dilakukan proses augmentasi untuk meningkatkan kemampuan generalisasi pada model.

```

vgg_base = VGG16(weights='imagenet',
                    include_top=False,
                    pooling='avg',
                    input_shape=(256, 256, 3))
vgg_base.trainable = True

# Fine-tune the last 4 layers
for layer in vgg_base.layers[:4]:
    layer.trainable = False

model = models.Sequential([
    vgg_base,
    layers.Dense(
        4096,
        activation='tanh',
        input_shape=512,
        kernel_regularizer=regularizers.l2(0.001)),
    layers.Dropout(0.6),
    layers.Dense(
        train_generator.num_classes,
        activation='softmax',
        kernel_initializer='uniform')
])

model.compile(
    optimizer='adam',
    loss='categorical_crossentropy',
    metrics=['accuracy'])

model.summary()

```

### C. Pembangunan dan Pelatihan Model

Model yang digunakan pada penelitian ini menggunakan arsitektur CNN, khususnya memanfaatkan model *pre-trained* VGG-16. Arsitektur ini cocok untuk pekerjaan klasifikasi dan pembelajaran pola visual yang kompleks. VGG-16 merupakan model yang sebelumnya telah dilatih terhadap *dataset* ImageNet, sehingga proses *fine-tuning* perlu dilakukan terhadap *dataset* batik. *Fine tuning* yang dilakukan terhadap model dasar VGG-16 hanya untuk empat lapisan terakhir agar lapisan yang lebih dalam dapat mempelajari fitur-fitur spesifik pada *dataset* batik sambil mempertahankan fitur general dari ImageNet.

Untuk mengadaptasi model VGG-16 pada penelitian ini, *layer* teratas dikecualikan dan menggunakan *average pooling* untuk melakukan kompresi dimensi spasial *feature map* menjadi vektor berukuran 512. Vektor ini akan menjadi masukan untuk *fully connected layer* yang terdiri dari 4096 unit dan diregularisasikan dengan penalti L2 untuk mencegah *overfitting*. Fungsi aktivasi yang digunakan adalah *tanh*. Lapisan berikutnya adalah *Dropout* untuk mencegah *overfitting* dengan *dropout rate* 0.6. Lapisan terakhir model terdiri dari lapisan *Dense* dengan banyaknya unit setara dengan banyaknya kelas pada *dataset*. Lapisan ini menggunakan fungsi aktivasi *softmax* untuk menghitung probabilitas kelas *output*. Arsitektur model ini di-*compile* dengan *Adam optimizer* dan *categorical cross-entropy loss function* yang cocok untuk klasifikasi multikelas. Untuk memantau kinerja model, akurasi dipilih sebagai metrik yang digunakan untuk pelatihan dan validasi.

Pelatihan model dilakukan untuk 10 *epoch* dan ukuran *batch* 32. Pelatihan menggunakan *dataset* yang sebelumnya

```

history = model.fit(
    train_generator,
    steps_per_epoch=train_generator.samples // BATCH_SIZE,
    epochs=10,
    validation_data=test_generator,
    validation_steps=test_generator.samples // BATCH_SIZE
)

```

### D. Uji Klasifikasi Model

Setelah proses pelatihan model dilakukan, model diuji untuk melakukan klasifikasi terhadap citra masukan. Keluaran hasil prediksi berupa label kelas yang diklasifikasikan oleh model.

```

def predict_single_image(img_path):
    img = image.load_img(img_path,
                          target_size=IMAGE_SIZE)
    img_array = image.img_to_array(img) / 255.0
    img_array = np.expand_dims(img_array, axis=0)

    prediction = model.predict(img_array)
    predicted_class = train_generator.class_indices
    class_label = {v: k for k,
                      v in predicted_class.items()}
    predicted_label = class_label[np.argmax(prediction)]

    # Display the image
    plt.imshow(image.load_img(img_path))
    plt.axis('off')
    plt.title(f"Predicted Label: {predicted_label}")
    plt.show()

predict_single_image('data/test/Ceplok/26.jpg')

```




### E. Evaluasi Model

Evaluasi dilakukan untuk mengukur kinerja model yang telah dilatih terhadap *dataset* latih. Proses evaluasi dilakukan dengan mengukur akurasi secara keseluruhan, akurasi rata-rata, dan juga metrik lainnya, yaitu *precision*, *recall*, *f1 score*, dan *support*. Semua metrik ini dirangkum pada *classification report*.

## V. HASIL

Model yang telah dilatih diuji untuk melakukan prediksi terhadap beberapa gambar pola batik. Gambar V.1 menunjukkan beberapa sampel citra motif batik untuk diklasifikasikan oleh model yang telah dilatih pada penelitian ini.




Gambar V.1. Uji klasifikasi batik


Untuk mengukur kinerja model, akurasi dipantau selama proses pelatihan dan validasi. Berdasarkan grafik pada Gambar V.2 dan Gambar V.3, akurasi rata-rata untuk pelatihan dan validasi tergolong tinggi, sedangkan *loss* rata-rata untuk pelatihan dan validasi tergolong rendah. Ini menunjukkan proses pembelajaran model yang sedikit fluktuatif. Pada *epoch* pertama, model menunjukkan akurasi sebesar 66.59% dengan *loss* 1.6805, yang meningkat signifikan pada *epoch* kedua menjadi 90.62% dengan *loss* 0.5323. Peningkatan ini mencerminkan kemampuan model untuk dengan cepat belajar dari data pelatihan. Untuk *epoch* berikutnya, akurasi pelatihan terus meningkat hingga mencapai puncak pada *epoch* keempat dengan akurasi 96.88% dan *loss* 0.2809. Namun, terjadi fluktuasi dengan penurunan performa pada beberapa *epoch*, yaitu *epoch* kelima dan ketujuh. Penurunan ini bisa

mengindikasikan *overfitting*. Akibatnya, model dapat menjadi terlalu spesifik terhadap data pelatihan dan kehilangan kemampuan generalisasi terhadap data baru, terutama pada kelas dengan jumlah data yang lebih sedikit.

Sementara itu, akurasi validasi konsisten berada di sekitar 95-97% sepanjang proses pelatihan, menunjukkan bahwa model memiliki generalisasi yang baik terhadap data validasi. Namun, variasi kecil dalam *loss* validasi menunjukkan bahwa model mungkin masih mengalami kesulitan dalam menyesuaikan beberapa aspek dari data validasi.



Gambar V.2. Akurasi selama proses pelatihan



Gambar V.3. Loss selama proses pelatihan

Selain memantau akurasi dan *loss* pada proses pelatihan dan validasi, kinerja model juga dapat dilihat dari beberapa metrik, seperti *precision*, *recall*, *f1 score*, dan *support*. Gambar V.4 menunjukkan hasil evaluasi model. Hasil prediksi menunjukkan kinerja yang sangat baik pada beberapa kelas seperti Kawung, Megamendung, Parang, dan Truntum, dengan nilai *precision*, *recall*, dan *f1 score* mendekati atau mencapai 1.00. Namun, kelas-kelas seperti Ceplok, Lereng, dan Nitik menunjukkan kinerja yang lebih rendah, khususnya kelas Lereng yang memiliki *recall* hanya 0.10 dan *f1 score* 0.17. Ini menunjukkan bahwa model memiliki kesulitan dalam mengklasifikasikan sampel dari kelas-kelas tersebut.

Rata-rata makro dari *precision*, *recall*, dan *f1 score* masing-masing sekitar 0.76, 0.76, dan 0.73, yang menunjukkan bahwa ada ketidakseimbangan performa antara kelas-kelas. Sementara itu, rata-rata berbobot memberikan gambaran yang lebih optimis dengan skor sekitar 0.95, namun ini dipengaruhi oleh performa tinggi pada kelas-kelas dengan lebih banyak sampel.

Classification Report				
	precision	recall	f1-score	support
Ceplok	0.65	0.73	0.69	15
Kawung	0.99	1.00	1.00	140
Lereng	0.50	0.10	0.17	10
Megamendung	1.00	1.00	1.00	150
Nitik	0.25	0.60	0.35	10
Parang	0.98	0.99	0.98	140
Truntum	0.98	0.91	0.94	150
accuracy			0.95	615
macro avg	0.76	0.76	0.73	615
weighted avg	0.96	0.95	0.95	615

Gambar V.4. Evaluasi model

Berdasarkan evaluasi, dapat diketahui bahwa kelas dengan jumlah data pelatihan yang besar, yaitu Kawung, Megamendung, Parang, dan Truntum memiliki skor metrik evaluasi yang lebih tinggi. Hal ini disebabkan karena banyaknya data pelatihan memberikan model lebih banyak kesempatan untuk belajar pola dari kelas-kelas ini melalui beragam variasi. Sementara itu, kelas dengan jumlah data pelatihan yang sedikit memiliki kinerja yang buruk karena model belum dapat menggeneralisasi pola pada motif batik. Akibatnya, model sering salah dalam mengenali sampel dari kelas ini, ditunjukkan melalui nilai *f1 score* yang rendah. Ketidakseimbangan dalam jumlah sampel antar kelas berkontribusi besar pada kinerja model yang tidak merata. Kelas dengan jumlah data yang besar mendominasi pembelajaran, sementara kelas dengan data lebih sedikit menjadi kurang terwakili dalam model, sehingga model memiliki bias terhadap kelas-kelas mayoritas, yang terlihat dari akurasi tinggi pada kelas-kelas tersebut dan akurasi rendah pada kelas minor.

## VI. KESIMPULAN DAN SARAN

Pemanfaatan CNN untuk klasifikasi motif batik Indonesia pada penelitian ini berhasil menghasilkan sebuah model dengan akurasi yang tinggi, yaitu senilai 95% untuk akurasi validasi rata-rata. Penggunaan VGG-16 sebagai model dasar yang di-*fine tuning* menggunakan *dataset* motif batik menunjukkan hasil yang baik dengan bantuan proses augmentasi data untuk menangani transformasi citra. Meskipun terdapat beberapa fluktuasi pada akurasi pelatihan, model ini dapat mempertahankan kinerja validasi yang konsisten.

Penelitian lebih lanjut dapat dilaksanakan untuk meningkatkan kinerja model agar model lebih *robust*, khususnya untuk citra motif batik yang dirotasi dan di-*scale*. *Dataset* pelatihan yang digunakan dapat dibuat lebih beragam dan banyak agar model dapat melakukan proses pelatihan dan pembelajaran dengan lebih baik. Dengan demikian, penelitian ini berkontribusi terhadap upaya melestarikan budaya Indonesia, khususnya untuk edukasi pengenalan pola motif batik.

## KODE PROGRAM

Berikut merupakan tautan repositori GitHub untuk kode program: <https://github.com/arleenchr/batik-classification>

## UCAPAN TERIMA KASIH

Puji syukur penulis panjatkan kepada Tuhan Yang Maha Esa atas berkat dan penyertaan-Nya sehingga penulis dapat menyusun makalah ini. Ucapan terima kasih penulis sampaikan kepada Bapak Dr. Ir. Rinaldi Munir, M.T., dosen pengampu mata kuliah IF4073 Pemrosesan Citra Digital, atas ilmu yang telah diajarkan selama masa perkuliahan sehingga penulis dapat menyelesaikan makalah ini. Penulis juga mengucapkan terima kasih kepada rekan-rekan mahasiswa peserta kuliah IF4073 Pemrosesan Citra Digital yang telah bekerja sama dan saling mendukung dalam proses penulisan makalah.

## REFERENSI

- [1] E. Steelyana, "Batik, A Beautiful Cultural Heritage that Preserve Culture and Supporteconomic Development in Indonesia," *Binus Business Review*, vol. 3, no. 1, p. 116, May 2012, doi: <https://doi.org/10.21512/bbr.v3i1.1288>.
- [2] Atika Atika, Nur Kholifah, Siti Nurrohmah, and Riski Purwiningsih, "Eksistensi Motif batik klasik pada generasi Z," *TEKNOBUGA Jurnal Teknologi Busana dan Boga*, vol. 8, no. 2, pp. 141–144, Jan. 2020, doi: <https://doi.org/10.15294/teknobuga.v8i2.29047>.
- [3] Farida Luwistiana and Sumiyatun Septianingsih, "Pergeseran Makna pada Motif Batik Tulis Banyumasan Bagi Masyarakat," *Prosiding Seminar Nasional LPPM UMP*, pp. 269–280, Dec. 2019.
- [4] R. Azhar, D. Tuwohingide, D. Kamudi, Sarimuddin, and N. Suciati, "Batik Image Classification Using SIFT Feature Extraction, Bag of Features and Support Vector Machine," *Procedia Computer Science*, vol. 72, pp. 24–30, 2015, doi: <https://doi.org/10.1016/j.procs.2015.12.101>.
- [5] Y. Gultom, A. M. Arymurthy, and R. J. Masikome, "Batik Classification using Deep Convolutional Network Transfer Learning," *Jurnal Ilmu Komputer dan Informasi*, vol. 11, no. 2, p. 59, Jun. 2018, doi: <https://doi.org/10.21609/jiki.v11i2.507>.
- [6] yohanesgultom, "GitHub - yohanesgultom/deep-learning-batik-classification: Batik motif classification (5 classes) using VGG16 transfer learning," *GitHub*, 2016, <https://github.com/yohanesgultom/deep-learning-batik-classification> (accessed Jan. 13, 2025).
- [7] Dionisius Darryl Hermansyah, "Indonesian Batik Motifs," *Kaggle.com*, 2020. <https://www.kaggle.com/datasets/dionisiusdh/indonesian-batik-motifs> (accessed Jan. 13, 2025).
- [8] arifnurrhmnn, "GitHub - arifnurrhmnn/Dataset-Motif-Batik: Dataset Motif Batik Kawung, Megamendung, Parang, Siomukti dan Truntum," *GitHub*, 2021. <https://github.com/arifnurrhmnn/Dataset-Motif-Batik> (accessed Jan. 13, 2025).
- [9] H. Nugroho, "Pengertian Motif Batik dan Filosofinya," *Balai Besar Kerajinan dan Batik*, Feb. 28, 2020. [https://bbkb.kemenperin.go.id/index.php/post/read/pengertian\\_motif\\_batik\\_dan\\_filosofinya\\_0](https://bbkb.kemenperin.go.id/index.php/post/read/pengertian_motif_batik_dan_filosofinya_0) (accessed Jan. 15, 2025).
- [10] Puspasari Setyaningrum, "Mengenal Motif Batik Kawung, Sejarah, Filosofi, dan Jenisnya," *KOMPAS.com*, Jan. 10, 2022. <https://regional.kompas.com/read/2022/01/10/172259678/mengenal-motif-batik-kawung-sejarah-filosofi-dan-jenisnya> (accessed Jan. 15, 2025).
- [11] Deka Noverma, "Mengenal Batik Ceplok, dari Asalnya hingga Variasi Motifnya," *Good News From Indonesia*, Sep. 23, 2023. <https://www.goodnewsfromindonesia.id/2023/09/23/mengenal-batik-ceplok-dari-asalnya-hingga-variati-motifnya>
- [12] "Sejarah Batik Parang," *Museum Sonobudoyo*, 2024. <https://sonobudoyo.jogjaprovo.go.id/id/tulisan/read/sejarah-batik-parang> (accessed Jan. 15, 2025).
- [13] anekabatik, "Motif Batik Lereng: Simbol Keindahan Alam Dan Keanggunan Budaya," *Aneka Batik*, May 14, 2024. <https://www.anekabatik.com/motif-batik-lereng-simbol-keindahan-alam-dan-keanggunan-budaya/> (accessed Jan. 15, 2025).

- [14] Balqis Fallahnda and Yulaika Ramadhani, "Mengenal Batik Mega Mendung, Motif Khas Cirebon & Arti Filosofi," *tirto.id*, Oct. 09, 2023. <https://tirto.id/mengenal-batik-mega-mendung-motif-khas-cirebon-arti-filosofi-gyZl>
- [15] "Motif Batik Nitik Asal Yogyakarta yang Bersejarah," *BatikIndonesia.com*, Dec. 31, 2021. <https://batikindonesia.com/motif-batik-nitik/> (accessed Jan. 15, 2025).
- [16] Art, "Batik Truntum Khas Yogyakarta | Sentra Batik Tulis Yogyakarta - Jual Batik Tulis Yogyakarta - Batik Tulis Yogyakarta Online - Wisata Batik Yogyakarta - Grosir Batik Tulis Yogyakarta - Pengrajin Batik Tulis Yogyakarta," *Sentra Batik Tulis Yogyakarta*, Sep. 26, 2015. <https://sentrabatiktulisyogyakarta.com/sejarah-dan-makna-filosofi-motif-batik-truntum-khas-yogyakarta/> (accessed Jan. 15, 2025).
- [17] Y. LeCun, Y. Bengio, and G. Hinton, "Deep Learning," *Nature*, vol. 521, no. 7553, pp. 436–444, May 2015, doi: <https://doi.org/10.1038/nature14539>.
- [18] S. Albawi, T. A. Mohammed, and S. Al-Zawi, "Understanding of a Convolutional Neural Network," *2017 International Conference on Engineering and Technology (ICET)*, pp. 1–6, Aug. 2017, doi: <https://doi.org/10.1109/icengtechnol.2017.8308186>.
- [19] J. Liu, "Convolutional Neural Network-Based Human Movement Recognition Algorithm in Sports Analysis," *Frontiers in Psychology*, vol. 12, Jun. 2021, doi: <https://doi.org/10.3389/fpsyg.2021.663359>.

## PERNYATAAN

Dengan ini saya menyatakan bahwa makalah yang saya tulis ini adalah tulisan saya sendiri, bukan saduran, atau terjemahan dari makalah orang lain, dan bukan plagiasi.

Bandung, 15 Januari 2024



Arleen Chrysanthia Gunardi  
NIM. 13521059